

Laporan UTS Machine Learning 2026

Informasi Mahasiswa:

- Nama: Mush'ab Abdurrahman Fathin
- NIM: 2411070062
- Project Link (W&B): <https://wandb.ai/mushab-a-fathin-stikomelrahma/uts-credit-card-fraud?nw=nwusermushabafathin>
- Pull Request Link (GitHub): https://github.com/MAF243/Machine-Learning-Course-2026/tree/main/assignments/week-08/2411070062_Mush'ab-Abdurrahman-Fathin

1. Problem Statement & Dataset

- Dataset apa yang Anda pilih?
- Apa masalah yang ingin diselesaikan (Klasifikasi/Regresi)?
- Mengapa masalah ini penting untuk diselesaikan dengan ML?

Jawaban:


1. Dataset yang saya pilih adalah Credit Card Fraud Detection dari OpenML (ID 1597). Dari dataset asli saya mengambil sampel 50.000 baris agar proses training lebih ringan, tetapi pola ketimpangannya tetap sama seperti data aslinya.
2. Masalah yang ingin diselesaikan adalah klasifikasi, yaitu memprediksi apakah sebuah transaksi termasuk normal (0) atau fraud (1).
3. Masalah ini penting diselesaikan dengan machine learning karena jumlah transaksi sangat banyak dan kasus fraud sering terselip di antara transaksi normal. Dengan model yang baik, bank bisa lebih cepat mendeteksi transaksi mencurigakan sebelum menimbulkan kerugian.


2. Exploratory Data Analysis (EDA)

- Ceritakan temuan menarik dari data Anda.
- Apakah ada korelasi kuat? Apakah ada data yang timpang (imbalanced)?
- Tampilkan visualisasi utama Anda.

Jawaban:

1. Temuan paling jelas dari data adalah ketimpangan kelas yang sangat ekstrem. Dari 50.000 transaksi, ada 49.917 transaksi normal dan hanya 83 transaksi fraud, jadi proporsi fraud hanya sekitar 0,166%.
2. Dari hasil `info()` dan pengecekan null, seluruh fitur yang dipakai sudah numerik dan tidak ada missing values yang berarti. Ini membuat proses preprocessing jadi lebih sederhana.
3. Distribusi `Amount` terlihat miring ke kanan. Sebagian besar transaksi bernilai kecil, tetapi ada beberapa transaksi bernilai sangat besar sehingga terlihat ada outlier.
4. Karena fitur V1 sampai V28 merupakan hasil PCA anonim, korelasi antar fitur tidak mudah dijelaskan secara bisnis. Jadi fokus analisis saya lebih banyak pada distribusi kelas, pola nominal transaksi, dan dampaknya terhadap pemilihan metrik evaluasi.
5. Visualisasi utama yang saya gunakan adalah grafik distribusi kelas dan distribusi `Amount`, karena dua grafik ini sudah cukup menunjukkan masalah inti dari dataset.





3. Preprocessing & Feature Engineering

- Langkah apa saja yang Anda lakukan (Handling missing values, Scaling, Encoding)?
- Jika data imbalanced, bagaimana Anda menanganinya? (SMOTE/Weighting)

Jawaban:

1. Saya memisahkan fitur dan target, lalu melakukan train-test split dengan `stratify` supaya proporsi kelas fraud dan normal tetap terjaga pada data train maupun test.
2. Karena semua fitur sudah numerik, saya tidak melakukan encoding tambahan. Saya juga tidak menemukan missing values yang perlu dibersihkan. Pada Logistic Regression saya tetap menambahkan median imputer di pipeline untuk menjaga alur preprocessing tetap aman.
3. Saya memakai `StandardScaler` pada Logistic Regression karena model linear cukup sensitif terhadap skala fitur. Untuk Random Forest dan XGBoost, scaling tidak menjadi syarat utama sehingga model dapat langsung dilatih pada data hasil SMOTE.
4. Untuk menangani imbalance, saya menggunakan SMOTE hanya pada data training. Setelah SMOTE, jumlah data training menjadi seimbang 50:50 dengan total 79.868 baris. Dengan cara ini model bisa belajar pola fraud dengan lebih adil.

4. Eksperimen Model (Battle of Algorithms)

Bandingkan performa minimal 3 model yang Anda pilih (Misal: MLP vs XGBoost vs Logistic Regression).

Hasil perbandingan model pada data test adalah sebagai berikut:

Model	Accuracy/RMSE	AUPRC/Recall	F1-Score
Logistic Regression	0.9831	0.6698 / 0.7647	0.1333
Random Forest	0.9993	0.6656 / 0.7059	0.7742
XGBoost	0.9991	0.7222 / 0.7647	0.7429

Analisis:

1. Logistic Regression memiliki Recall tinggi, tetapi Precision sangat rendah. Artinya model ini terlalu sering memberi alarm palsu pada transaksi normal.
2. Random Forest mempunyai Accuracy tertinggi dan Precision paling baik. Namun Recall-nya sedikit lebih rendah sehingga masih ada fraud yang lolos lebih banyak dibanding XGBoost.
3. XGBoost memiliki AUPRC tertinggi dan Recall yang tetap tinggi. Karena tugas ini fokus pada kasus fraud yang imbalanced, saya memilih XGBoost sebagai model terbaik.

5. Analisis Hasil & W&B Tracking

- Berdasarkan dashboard W&B, model mana yang paling unggul?
- Analisis Confusion Matrix: Bagaimana model Anda menangani False Positive/Negative?
- Fitur apa yang paling berpengaruh (Feature Importance)?


Jawaban:


1. Berdasarkan dashboard W&B, model yang paling unggul adalah XGBoost. Walaupun Random Forest mempunyai Accuracy sedikit lebih tinggi, XGBoost menghasilkan AUPRC tertinggi yaitu 0.7222, sehingga lebih kuat dalam membedakan fraud di tengah transaksi normal yang sangat banyak.

2. Dari confusion matrix, Logistic Regression menghasilkan FP yang sangat banyak yaitu 165. Artinya model ini terlalu agresif menandai transaksi normal sebagai fraud. Random Forest jauh lebih ketat dengan FP hanya 2, tetapi FN-nya 5. XGBoost memberi kompromi yang lebih seimbang dengan TN=9978, FP=5, FN=4, dan TP=13.

3. Untuk kasus fraud, False Negative sangat penting karena artinya transaksi fraud lolos sebagai transaksi normal. Pada hasil ini, XGBoost dan Logistic Regression sama-sama mempunyai FN=4, sedangkan Random Forest mempunyai FN=5.

4. Berdasarkan grafik feature importance, fitur yang paling berpengaruh pada model terbaik adalah V14. Setelah itu terlihat V10, V4, V17, dan V13 juga cukup dominan. Selain fitur PCA tersebut, 'Amount' juga masih ikut memberi kontribusi pada prediksi.





6. Kesimpulan & Rekomendasi

- Apakah model Anda sudah siap digunakan di dunia nyata?
- Apa keterbatasan model Anda saat ini?

Jawaban:

1. Menurut saya, model ini sudah cukup baik untuk dijadikan sistem pendukung keputusan awal, tetapi belum layak dipakai sendirian di dunia nyata. Alasannya, jumlah fraud pada data test hanya 17 kasus, jadi satu atau dua kesalahan saja sudah berpengaruh besar.
2. Keterbatasan model saat ini adalah data yang dipakai masih berupa sampel 50.000 baris, fitur-fitur PCA tidak mudah dijelaskan secara bisnis, dan threshold prediksi belum dioptimalkan. Selain itu, model belum diuji pada data yang benar-benar baru dari periode waktu berbeda.
3. Jika sistem ini ingin dipakai lebih serius, langkah lanjut yang menurut saya penting adalah menguji model pada data yang lebih besar, menyesuaikan threshold sesuai biaya kesalahan, dan menggabungkan model dengan pemeriksaan manual untuk transaksi yang paling berisiko.